

Reflexion: Language Agents with Verbal Reinforcement Learning

Noah Shinn, Federico Cassano et al. (Northeastern Univ., Princeton Univ.) · NeurIPS 2023 / arXiv 2023

Motivation

파인튜닝 없는 실시간 피드백 반영 및 ReAct의 반복적 오류(무한 루프) 극복

전통적인 강화학습에 기반한 기존 방법의 한계

RLHF

작동 방식

선호도 평가 데이터 기반 fine-tuning (SFT)
→ 보상 모델 (RM)
→ SFT policy fine-tuning (PPO)

한계

- 방대한 학습 샘플 & 가중치 업데이트
: 학습 과정에 비용과 시간 ↑
- 학습 완료 후 실시간 피드백 반영 어려움

ReAct



작동 방식

생각 (Reasoning)
→ 행동(Action: 외부 도구/API 호출)
→ 관찰(Observation) 루프 반복

한계

- 단기 메모리
: 실패 원인을 돌아보고 학습하는 메커니즘 부재
- 무한 루프 및 실패 행동 반복

Pipeline



Results

다양한 형태와 출처의 피드백 신호를 유연하게 수용할 수 있음

피드백 형태

- Scalar values : 수치 형태의 신호 (예: "테스트 10개 중 8개 통과")
- Free-form language : 말로 된 자유 형식 설명 (예: "3번째 줄에서 타입 에러가 났어")

피드백 출처

- 외부 (External) : 환경, 컴파일러, 인터프리터, 테스트 결과 등 외부에서 주어지는 신호
- 내부 시뮬레이션 (Internal) : 에이전트(LM)가 스스로 만든 평가·시뮬레이션
(예: Evaluator LM이 생성한 자체 평가)

어떤 형태·출처의 피드백이든 Self-Reflection 단계에서 자연어 오답노트로 변환되므로, 별도의 가중치 업데이트 없이 통합할 수 있음

Results

다양한 과제에서 기준 에이전트 (ReAct) 대비 비약적인 성능 향상

순차적 의사결정 (Sequential decision-making)

- 목적: 긴 궤적(trajecory)에 걸친 선택 능력 테스트

- AlfWorld

: 12번의 반복 학습 단계 동안 baseline 접근 방식 대비 절대 수치로 22% 향상




Figure 3: (a) AlfWorld performance across 134 tasks showing cumulative proportions of solved tasks using self-evaluation techniques of (Heuristic) and (GPT) for binary classification. (b) Classification of AlfWorld trajectories by reason of failure.

Results

다양한 과제에서 기준 에이전트 (ReAct) 대비 비약적인 성능 향상

언어 추론 (Language reasoning)

- 목적: 단일 단계 생성 개선 테스트

- HotPotQA

: 추론 질문에서 20% 향상




Figure 4: Chain-of-Thought (CoT) and ReAct. Reflexion improves search, information retrieval, and reasoning capabilities on 100 HotPotQA questions. (a) Reflexion ReAct vs Reflexion CoT (b) Reflexion CoT (GT) for reasoning only (c) Reflexion vs episodic memory ablation.

Results

다양한 과제에서 기존 에이전트 (ReAct) 대비 비약적인 성능 향상

코딩 (Coding)

- 목적: 에이전트가 컴파일러, 인터프리터 등 외부 도구를 효과적으로 사용하도록 학습
- HumanEval
 - : Python 프로그래밍 과제에서 최대 11% 향상 (pass@1 91%로 GPT-4의 80%를 넘어섬)

Benchmark + Language	Prev SOTA Pass@1	SOTA Pass@1	Reflexion Pass@1
HumanEval (PY)	65.8 (CodeT [5] + GPT-3.5)	80.1 (GPT-4)	91.0
HumanEval (RS)	–	60.0 (GPT-4)	68.0
MBPP (PY)	67.7 (CodeT [5] + Codex [6])	80.1 (GPT-4)	77.1
MBPP (RS)	–	70.9 (GPT-4)	75.4
Leetcode Hard (PY)	–	7.5 (GPT-4)	15.0

Table 1: Pass@1 accuracy for various model-strategy-language combinations. The base strategy is a single code generation sample. All instruction-based models follow zero-shot code generation.

Limitations

Local Minima 함정 발생 가능성

자연어 기반의 정책 최적화 방식을 사용하므로, 잘못된 방향으로 반성이 고착될 경우
최적이 아닌 해결책에 빠질 위험 존재

슬라이딩 윈도우 메모리의 한계 (Memory Capacity)

메모리가 용량이 제한된 단순 슬라이딩 윈도우 구조로 되어 있어, 오래된 오답노트가 삭제될 수 있음

Test-Driven Development (TDD)의 실질적 한계

코딩 영역에서, API 호출이나 동시성 처리처럼 단위 테스트로 쉽게 검증하기 힘든 복잡한 코드 환경에서는
평가와 피드백 생성이 어렵다

Conclusion & Impact

언어적 강화학습 패러다임 제시

가중치 업데이트 없이 자연어 반성만으로 agent가 과거의 실수로부터 지속 학습함을 입증함
기존 Decision-making 접근 방식 대비 현격한 성능 우수성 보이며, 해석 가능성 및 안정성이 향상됨

ReAct 대비 핵심 개선점

가중치 업데이트 없이 자연어 오답노트(Self-Reflection)를 장기 메모리에 저장하여 다음 시도에 활용하는 구조를 구축함
단순 행동 반복 및 실행 로그 누적으로 인한 ReAct의 무한 루프와 토큰 낭비 문제를 극복하고 자율적 오답 복기 능력을 확보함

현대 AI Agent 생태계에 미친 영향

파인튜닝 없는 메모리 기반 자율 개선(Self-Correction) 에이전트 architecture의 초석을 마련함